

Академические инициативы Яндекса

Павел Браславский



Академические инициативы

- Школа Анализа Данных
- Семинары Яндекса
- Интернет-математика
- РОМИП
- Школа по информационному поиску (RuSSIR)
- Книга «Введение в информационный поиск»

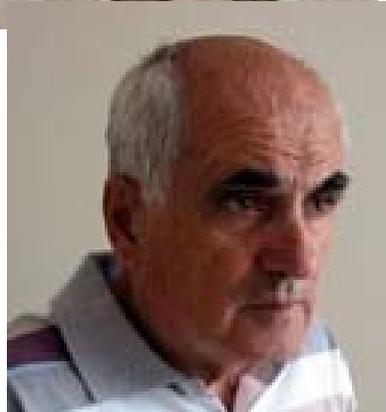
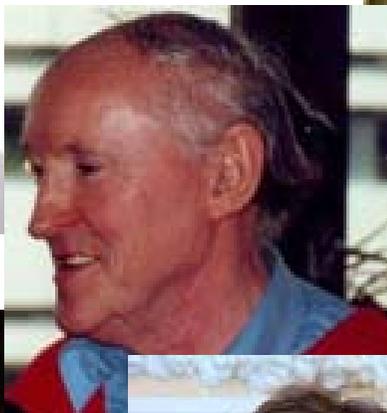
Yandex School of Data Analysis



two-year master program, <http://shad.yandex.ru>



Teachers



Scientific seminars

Monthly seminars on Data analysis & information retrieval

Organized by
Microsoft Research +
Яндекс



<http://company.yandex.ru/public/seminars/schedule/>



IMAT 2009

- Learning to rank
- 245 features for query-document pairs
- Graded relevance judgments (0..4)
- Pure numeric data (i.e. no original queries, documents or feature semantics)
- Learning set: 97 290 feature vectors (9 124 queries)
- Test set: 115 643 vectors (21 103 – public evaluation; 94 540 – final evaluation)
- Evaluation measure: DCG
- <http://imat2009.yandex.ru>

Рейтинг

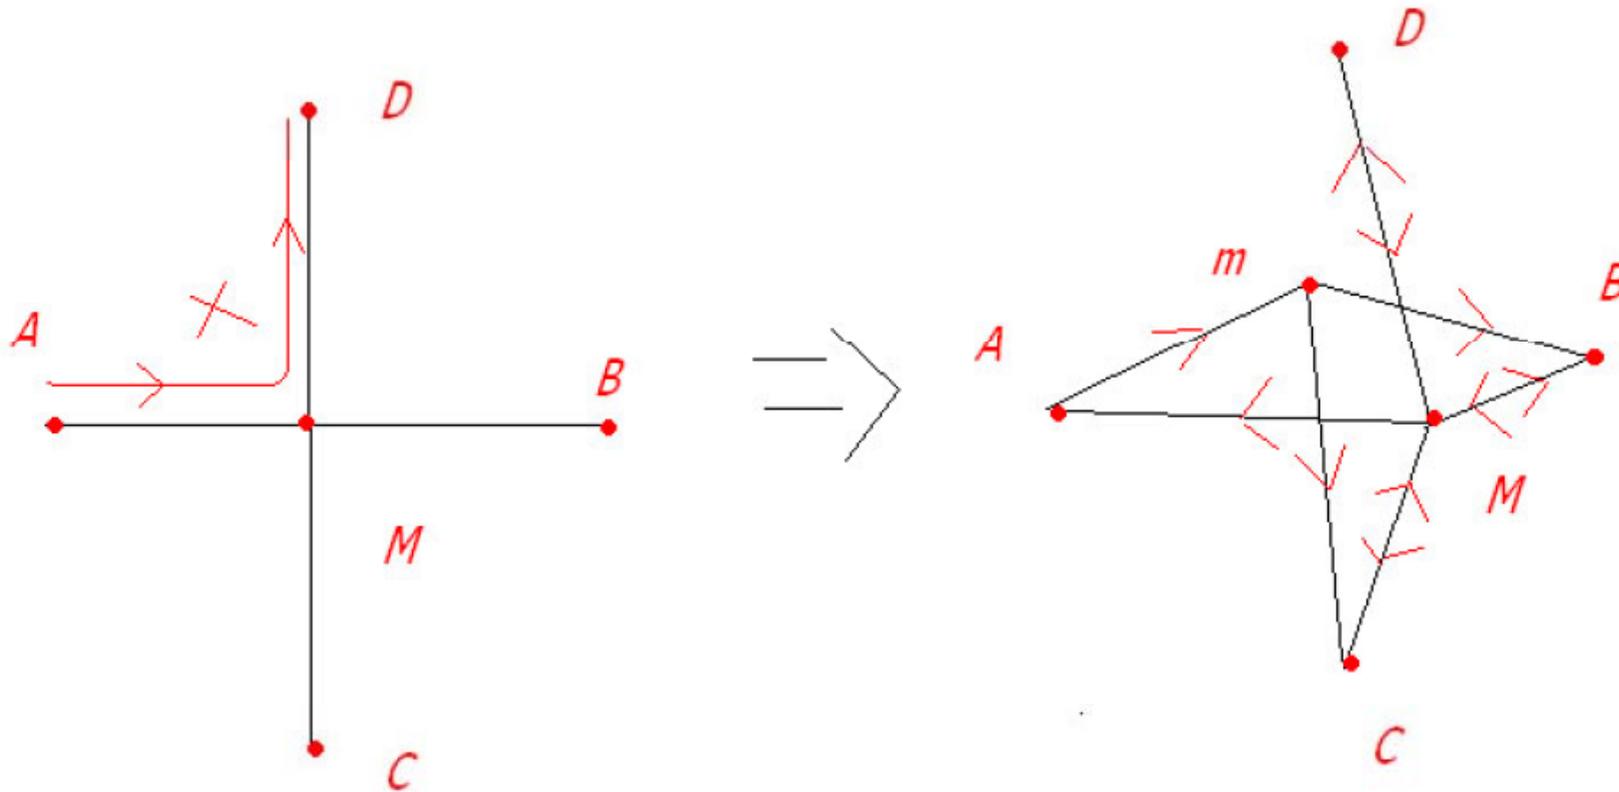
Таблица объединяет финальный рейтинг конкурса (на 15.05.2009) и новые результаты. Подробнее о задаче и методике оценки см. [о конкурсе](#) и раздел [Задачи и данные](#).

Команда	Время последней загрузки	Количество попыток	Последний результат (публичная оценка)	Финальный результат
alexeigor1	07.04.2010 (16:08 GMT+03)	1	4.284426	4.156340
Всем чмоке в этом чате :)	14.02.2010 (19:03 GMT+03)	4	4.283924	4.133886
Joker	05.09.2009 (05:07 GMT+03)	2	4.283317	4.151528
Сам	21.02.2010 (20:57 GMT+03)	187	4.282790	4.147628
-F	02.12.2009 (16:44 GMT+03)	2	4.281325	4.145202
alexeigor	07.05.2009 (17:02 GMT+03)	118	4.280676	4.141230
AG	03.05.2010 (02:13 GMT+03)	1	4.279520	4.148574
derpechemode	29.10.2009 (01:19 GMT+03)	30	4.278378	4.142855
RelevanceDoesMatter	24.09.2010 (18:58 GMT+03)	448	4.276658	4.135519
Победа	17.03.2009 (16:25 GMT+03)	3	4.276001	4.139854
Simple	24.09.2010 (19:17 GMT+03)	581	4.275371	4.132883
ACGT	15.05.2009 (14:03 GMT+03)	21	4.274666	4.128807
stochastic	25.10.2009 (23:37 GMT+03)	819	4.274414	4.129173
Злобный Терминатор	03.09.2010 (15:52 GMT+03)	14	4.269719	4.132461
aport	13.09.2010 (10:45 GMT+03)	14	4.269432	4.123704
ПушистаяПуська	06.05.2010 (11:26 GMT+03)	1	4.268557	4.128603
WoodWeb	22.04.2009 (23:09 GMT+03)	12	4.267894	4.127512
Nordic	15.05.2009 (23:37 GMT+03)	4	4.266904	3.857102
stochastic	15.05.2009 (23:43 GMT+03)	176	4.266712	4.118830
Михаил	11.11.2010 (11:59 GMT+03)	2	4.266247	—
Euclid	27.02.2010 (05:40 GMT+03)	124	4.265264	4.139924
Test	15.05.2009 (23:45 GMT+03)	58	4.264024	3.859052
ZENIT	15.05.2009 (23:20 GMT+03)	206	4.259964	4.117877

IMAT 2010

- Traffic congestion prediction
- (Rough) data:
 - Modified graph of Moscow streets
 - Observed traffic speed 4-10 pm (4-min intervals) for 30 subsequent days + 4-6 pm on the 31st day
- Task: predict traffic speed 6-10 pm of the 31st day
- public/final evaluation
- <http://imat2010.yandex.ru>

Modified graph of streets



IMAT 2010 Data

- Graph: vertices (139 241/33 029) and edges (206 260/86 249)
 - <id_vertex> <id_group>
 - <id_edge> <id_edge_group> <start_vert> <end_vert>
 - <id_edge_group> <length> <avg_speed>
- Observations (learning set, 29 226 208 lines)
 - <id_edge_group> <day> <time> <speed>
- Task (691 641 lines)
 - <id_edge_group> <day> <time> ??
- Evaluation

$$Err(a) = \frac{1}{n} \sum_{i=1}^n l_i t_i |a_i - v_i|$$

Рейтинг

Таблица объединяет финальный рейтинг конкурса (на 16.05.2010) и новые результаты. Подробнее о задаче и методике оценки см. [Задача и данные](#).

Baseline — это «простая скептическая оценка»: средняя скорость для дуги по всем дням месяца для этого момента времени; если данных нет, то считаем, что скорость 0 км/ч (пробка).

Команда	Время последней загрузки	Количество попыток	Последний результат (публичная оценка)	Финальный результат
Сергей Гуда и Денис Рябов (ЮФУ)	16.05.2010 (23:21 GMT+03)	487	57.252870	58.924831
Паровоз	16.05.2010 (23:40 GMT+03)	252	58.137167	59.039501
malk	16.05.2010 (22:16 GMT+03)	9	58.352243	59.450132
RomanL	16.05.2010 (23:49 GMT+03)	252	60.117079	60.021672
УрГУ	16.05.2010 (23:50 GMT+03)	49	58.355595	60.156530
test	16.05.2010 (23:16 GMT+03)	246	58.427409	60.165762
Здравый смысл	31.07.2010 (15:27 GMT+03)	2	59.955410	60.229683
SlowMotion	16.05.2010 (20:51 GMT+03)	138	59.026925	60.264464
View	16.05.2010 (19:05 GMT+03)	87	59.470813	60.349985
Здравый смысл	16.05.2010 (01:20 GMT+03)	59	59.823316	60.372594
ММП	16.05.2010 (15:36 GMT+03)	241	59.996702	60.745338
GoGo	16.05.2010 (20:46 GMT+03)	49	60.911306	61.392298
kek_ksu	16.05.2010 (23:18 GMT+03)	28	60.452621	61.556647
DmitryS	16.05.2010 (23:38 GMT+03)	130	61.238659	61.744422
Kejpa	16.05.2010 (11:52 GMT+03)	73	60.728057	61.907533
Евгений Краско	16.05.2010 (14:13 GMT+03)	133	60.823800	61.977751
deas	15.05.2010 (23:27 GMT+03)	19	63.136674	62.022574
prognoz1	16.05.2010 (18:40 GMT+03)	21	62.245653	62.334491

ИМАТ 2011

Старт конкурса – февраль 2011

Задача интересная, победителю – приз 😊

ROMIP

- TREC-like Russian initiative
- Started 2002
- Several text and image collections
- 10-15 participants per year (total 50+)
 - Academia and industry, students support
- ~3 000 man-hours of evaluation (2009)
- Remote participation + live meeting
- Collections are freely available
- Popular testbed for IR research in Russia



ROMIP largest text collections

Collection	Documents	Size (compressed)	Topics	Evaluated within ad-hoc search track
Legal	~300 000	2 Gb	14 794	220
By.Web	1 524 676	8 Gb	~ 60 000	1 500+
KM.RU	3 010 455	13 Gb	~ 60 000	~250

Image collections

- Photo collection: 20 000 images from **Flickr**
- Dups collection: 15 hrs video → 37 800 frames



RuSSIR



- Yekaterinburg, 5-12 September 2007
<http://romip.ru/russir2007>
- Taganrog, 1-5 September 2008
<http://romip.ru/russir2008/>
- Petrozavodsk, 11-16 September 2009
<http://romip.ru/russir2009/>
- Voronezh, 13-18 September 2010
<http://romip.ru/russir2010/>
- Saint Petersburg, 15-19 August 2011
<http://romip.ru/edbt-russir2011/>

RuSSIR



Информационный поиск по-русски



Оригинальная английская версия: <http://informationretrieval.org>

Яндекс

Павел Браславский
pb@yandex-team.ru